ChargeGrid AI | Evolucao Sprint 04

FIAP x GoodWe EV Challenge | Relatorio de evolucao | 28/10/2026

Resumo executivo

O ChargeGrid foi estendido com um assistente de IA baseado em Recuperacao Aumentada por Geracao (RAG). O objetivo e responder a perguntas sobre carregadores GoodWe usando documentos tecnicos oficiais, com citacoes de fonte e pagina. A interface web funcional demonstrada e Gradio; a integracao React foi tentada, mas nao validada.

Evolucao por etapa

Aspecto	Sprints anteriores	Sprint 04
Foco	Gestao e fluxo de carregamento	Chatbot tecnico GoodWe
Dados	Estados e operacoes da plataforma	Manuais e fichas tecnicas PDF
Inteligencia	Regras e insights operacionais	RAG com Ollama + ChromaDB
Acesso	Interface do ChargeGrid	Web Gradio independente
Avaliacao	Fluxos funcionais	5 perguntas e notas manuais

Pipeline RAG

PDFs GoodWe -> PyMuPDFLoader -> chunking 512/overlap 64 -> embeddings nomic-embed-text -> ChromaDB persistente -> top-20 -> reranker multilingue -> top-5 -> gemma4:cloud -> resposta com referencias -> Gradio.

Configuracoes experimentais

Chunking comparado: 256, 512 e 1024 caracteres. Na indexacao inicial de quatro PDFs: 243 unidades; 1248/647/387 chunks, respectivamente. Depois foi incluida ficha tecnica HCA G2 e reconstruida a colecao.

Avaliacao de versoes (notas manuais)

Versao	Faithfulness	Relevancia	Interpretacao
V1	1,00	0,90	Baseline
V2 monolingue	0,90*	0,55*	Regressao
V2.1 multilingue	1,00	0,85	Recuperacao parcial

*V2 monolingue: notas preliminares. A V2.1 cresceu +0,30 em relevancia sobre V2, mas ainda ficou -0,05 abaixo da V1. Nao ha comprovacao de duas iteracoes com ganhos positivos sobre a baseline.

Dois problemas e intervencoes

1. Mistura entre HCA e HCA G2: adicionou-se ficha tecnica especifica e roteamento conservador; a resposta de potencias passou a citar o documento correto. **2. Reranking monolingue:** prejudicou a busca em portugues; troca por modelo multilingue recuperou parte da relevancia. **Limitacao mantida:** etapas completas de instalacao nao aparecem nos trechos recuperados, que privilegiam seguranca e verificacoes pos-instalacao.

Comparacao de dois modelos

Com cinco perguntas e parametros registrados temperature=0, top_p=0.9, num_predict=512, k inicial=20 e k final=5: Gemma 4 Cloud respondeu 5/5, tempo medio 4.82s; Qwen3 4B apresentou raciocinio em ingles no texto, sem resposta final adequada em 4/5 e falha de formato na quinta, tempo medio 27.39s. Esses tempos incluem todo o pipeline, nao apenas inferencia. Gemma foi selecionado para demonstracao.

Riscos, qualidade e proxima verificacao

Prompt exige grounding, citacoes e recusa fora da documentacao; o teste sobre tarifa sem fonte gerou recusa apropriada no Gemma. Falta teste adversarial formal de prompt injection, verificacao automatica de citacoes e ganho de duas iteracoes medido contra a baseline. Esses itens nao devem ser apresentados como concluidos.

Responsabilidades e entrega

Equipe e divisao de atividades: [PREENCHER COM DADOS REAIS]. Entrega: link do repositorio publico na branch sprint-04-rag, TXT dos integrantes e este PDF de evolucao (maximo cinco paginas). Relatorios complementares em docs/ e experimentos em evals/.